

Feature Engineering Documentation

Simulasi Industri Junior Data Analyst — Minggu 3, Hari Kamis

Dataset: monster_com-job_sample.csv (US Jobs on Monster.com)

1. Ringkasan

Dokumen ini mencatat proses Data Preparation yang dilakukan terhadap Clean Dataset v2 (hasil standardisasi Hari Rabu), mencakup Feature Selection (penghapusan kolom yang tidak relevan) dan Feature Engineering (pembuatan kolom baru), untuk menghasilkan Final Clean Dataset yang siap dipakai pada Minggu 4 - Exploratory Data Analysis.

2. Feature Selection: Kolom yang Dihapus

Lima kolom dihapus dari dataset karena nilainya seragam di hampir seluruh baris (tidak memberi informasi tambahan untuk analisis) atau tidak relevan untuk kebutuhan analisis data lowongan kerja.

Kolom Dihapus	Alasan
Country	Seragam: 100% bernilai "United States of America"
Country_Code	Seragam: 100% bernilai "US"
Job_Board	Seragam: 100% bernilai "jobs.monster.com"
Has_Expired	Seragam: 100% bernilai "No"
Page_URL	Hanya tautan referensi, tidak relevan untuk analisis

Hasil: jumlah kolom berkurang dari 13 menjadi 8 kolom inti (Job_Title, Job_Type, Location, Organization, Salary, Sector, Job_Description, Unique_ID).

3. Feature Engineering #1: Location_State

Kolom baru **Location_State** dibuat dengan mengekstrak kode negara bagian (2 huruf kapital) dari kolom Location menggunakan regular expression, karena format Location pada umumnya berupa "Kota, Kode_State Kode_Pos" (contoh: "Madison, WI 53702"). Kolom ini berguna untuk analisis distribusi lowongan kerja per negara bagian pada tahap EDA.

Metrik	Nilai
Total baris	19.962
Berhasil diekstrak	17.846 (89,4%)
Gagal diekstrak (NaN)	2.116 (10,6%)
5 Negara Bagian Teratas	TX (2.792), OH (2.059), CA (1.597), FL (815), IL (813)

Catatan: kegagalan ekstraksi pada 2.116 baris (10,6%) terjadi karena beberapa nilai pada kolom Location tidak mengikuti format standar "Kota, State" — sejalan dengan temuan pada Data Standardization Report Hari Rabu bahwa sebagian isi kolom Location berupa data tidak valid (bukan format lokasi).

4. Feature Engineering #2: Job_Description_Length

Kolom baru **Job_Description_Length** dibuat untuk menghitung jumlah karakter pada kolom Job_Description. Kolom ini dapat digunakan sebagai indikator seberapa detail sebuah lowongan kerja dideskripsikan, dan berpotensi dikorelasikan dengan faktor lain (misalnya Job_Type atau Sector) pada tahap EDA.

Statistik	Nilai (jumlah karakter)
Rata-rata (mean)	2.479,76
Median	2.195,50
Minimum	16
Maksimum	20.189
Standar Deviasi	1.607,35

5. Struktur Dataset Akhir

Final Clean Dataset terdiri dari 19.962 baris dan 10 kolom (8 kolom inti hasil Feature Selection ditambah 2 kolom hasil Feature Engineering):

No	Kolom	Keterangan
1	Job_Title	Judul lowongan pekerjaan
2	Job_Type	Kategori tipe pekerjaan (hasil standardisasi Hari Rabu)
3	Location	Lokasi pekerjaan
4	Organization	Nama perusahaan/organisasi
5	Salary	Informasi gaji
6	Sector	Sektor industri
7	Job_Description	Deskripsi lengkap pekerjaan
8	Unique_ID	ID unik tiap baris data
9	Location_State	(Baru) Kode negara bagian hasil ekstraksi dari Location
10	Job_Description_Length	(Baru) Jumlah karakter pada Job_Description

6. Output

Hasil akhir proses Data Preparation disimpan sebagai **Final Clean Dataset** (.csv), yang menjadi dasar untuk tahap Exploratory Data Analysis (EDA) pada Minggu 4.