

Data Standardization Report

Simulasi Industri Junior Data Analyst — Minggu 3, Hari Rabu

Dataset: monster_com-job_sample.csv (US Jobs on Monster.com)

1. Ringkasan

Laporan ini mendokumentasikan proses standardisasi format yang dilakukan terhadap Clean Dataset v1 (hasil cleaning missing value & duplicate pada Hari Selasa), untuk menghasilkan Clean Dataset v2. Standardisasi mencakup: penyeragaman kategori pada kolom job_type, penghapusan spasi berlebih pada kolom teks, penyeragaman format huruf pada job_title, dan penamaan ulang kolom agar konsisten.

2. Standardisasi Kolom job_type

Kolom job_type pada data asli memiliki 39 variasi penulisan berbeda untuk makna yang sama (contoh: "Full Time", "Full Time Employee", "Full Time, Employee", "Job Type Full Time Employee"). Nilai-nilai tersebut disederhanakan menjadi 6 kategori standar berdasarkan kata kunci yang terkandung di dalamnya.

Kategori Standar	Jumlah Baris	Contoh Nilai Asli
Full Time	17.311	Full Time; Full Time Employee; Full Time, Employee
Contract/Temporary	1.904	Temporary/Contract/Project; Full Time Temporary/Contract/Project
Part Time	933	Part Time; Part Time Employee
Other	149	Employee; Exempt
Per Diem	67	Per Diem; Per Diem Employee
Intern	8	Full Time Intern; Part Time Intern
(Kosong / NaN)	1.628	-

Hasil: jumlah kategori unik berkurang dari 39 menjadi 6, sehingga kolom job_type kini siap digunakan untuk agregasi dan analisis pada Minggu 4.

3. Penghapusan Spasi Berlebih (Trim)

Seluruh kolom bertipe teks diperiksa dan dibersihkan dari spasi berlebih di awal/akhir nilai. Kolom yang terdampak:

Kolom	Jumlah Baris Terdampak
job_description	3.371
location	165
salary	29
job_type	15
sector	4

organization	3
--------------	---

4. Standardisasi Penulisan Huruf

Kolom `job_title` diseragamkan formatnya menjadi Title Case (huruf kapital di awal setiap kata) agar konsisten dan mudah dibaca, contoh: "business reporter/editor job in madison" menjadi "Business Reporter/Editor Job In Madison".

5. Penamaan Ulang Kolom (Rename)

Seluruh nama kolom diseragamkan ke format kapital di awal kata dengan underscore, agar konsisten dan lebih profesional untuk dipakai pada tahap analisis selanjutnya.

Nama Kolom Lama	Nama Kolom Baru
<code>job_title</code>	<code>Job_Title</code>
<code>job_type</code>	<code>Job_Type</code>
<code>organization</code>	<code>Organization</code>
<code>location</code>	<code>Location</code>
<code>salary</code>	<code>Salary</code>
<code>sector</code>	<code>Sector</code>
<code>job_description</code>	<code>Job_Description</code>
<code>has_expired</code>	<code>Has_Expired</code>
<code>job_board</code>	<code>Job_Board</code>
<code>page_url</code>	<code>Page_URL</code>
<code>uniq_id</code>	<code>Unique_ID</code>

6. Catatan Tambahan (Ditemukan Selama Standardisasi)

Selama proses trimming, ditemukan bahwa 165 baris pada kolom `location` tidak hanya memiliki masalah spasi, tetapi juga berisi data yang tidak valid (bukan lokasi), seperti deskripsi pekerjaan yang panjang atau nama kontak (contoh: "Contact name Tony Zerio"). Masalah ini tergolong sebagai isu "Data Tidak Valid" dan direkomendasikan untuk ditangani secara terpisah pada tahap Data Preparation (Hari Kamis), karena memerlukan pendekatan yang berbeda dari sekadar standardisasi format.

7. Output

Hasil akhir standardisasi disimpan sebagai **Clean Dataset v2** (.csv), yang menjadi dasar untuk proses Data Preparation dan Feature Engineering pada Hari Kamis.