

Correlation Analysis Report

Topik 4 — Exploratory Data Analysis (EDA)

Minggu 6 · Hari Kamis — Korelasi Data

Dataset	Salary Data.csv (Salary Prediction for Beginners — Kaggle)
Jumlah Data	375 baris awal -> 373 baris setelah dropna()
Kolom Numerik	Age, Years of Experience, Salary
Kolom Kategorikal	Gender, Education Level, Job Title (di-encode untuk analisis tambahan)
Metode	Pearson Correlation Matrix + Heatmap (seaborn)

Laporan ini menyajikan analisis korelasi (correlation analysis) untuk mengidentifikasi kekuatan dan arah hubungan antar variabel numerik pada dataset gaji karyawan. Analisis mencakup correlation matrix, heatmap, serta identifikasi variabel independen dan dependen yang relevan untuk pengambilan keputusan bisnis.

1

Gambaran Dataset

Dataset berisi 375 baris data karyawan dengan 6 kolom: **Age**, **Gender**, **Education Level**, **Job Title**, **Years of Experience**, dan **Salary**. Setelah menghapus 2 baris dengan nilai kosong (dropna), tersisa **373 baris** data bersih yang digunakan untuk analisis korelasi.


Kolom	Tipe Data	Missing (sebelum dropna)
Age	float64	2
Gender	object	2
Education Level	object	2
Job Title	object	2
Years of Experience	float64	2
Salary	float64	2

INSIGHT

- Missing values sangat minim (hanya 2 dari 375 baris, ~0,5%), sehingga proses dropna() tidak berdampak signifikan terhadap representativitas data.
- Terdapat 3 kolom numerik murni (Age, Years of Experience, Salary) yang bisa langsung dianalisis korelasinya menggunakan Pearson correlation.
- Kolom kategorikal (Gender, Education Level, Job Title) memerlukan proses encoding sebelum bisa dimasukkan ke dalam correlation matrix.

Tabel 2.1 — Correlation Matrix: Age, Years of Experience, Salary

	Age	Years of Experience	Salary
Age	1,00	0,98	0,92
Years of Experience	0,98	1,00	0,93
Salary	0,92	0,93	1,00



Gambar 2.1 — Heatmap correlation matrix (Age, Years of Experience, Salary)


INSIGHT

- **Age dan Years of Experience** memiliki korelasi sangat kuat ($r = 0,98$) — hampir sempurna, sesuai logika bahwa semakin tua usia karyawan, semakin lama pula pengalaman kerjanya.
- **Years of Experience dan Salary** berkorelasi sangat kuat ($r = 0,93$) — sedikit lebih tinggi dibanding korelasi Age-Salary (0,92), menunjukkan pengalaman kerja sedikit lebih berpengaruh terhadap gaji dibanding usia semata.
- Ketiga variabel menunjukkan korelasi **positif dan kuat** (semua di atas 0,90) — mengonfirmasi hubungan yang logis: makin tua & makin berpengalaman, gaji cenderung makin tinggi.
- Karena Age dan Years of Experience sama-sama berkorelasi sangat tinggi terhadap Salary, ada indikasi **multikolinearitas** antara Age dan Years of Experience itu sendiri — penting diperhatikan jika data ini nantinya dipakai untuk model prediksi (regresi).

Correlation Matrix — Termasuk Variabel Kategorikal (Encoded)

Untuk memperkaya analisis, kolom **Gender** dan **Education Level** di-encode menjadi numerik menggunakan LabelEncoder, lalu dimasukkan kembali ke dalam correlation matrix.

	Age	Years of Exp.	Salary	Gender_Enc	Education_Enc
Age	1,00	0,98	0,92	-0,02	0,56
Years of Experience	0,98	1,00	0,93	0,00	0,59
Salary	0,92	0,93	1,00	0,07	0,67
Gender_Encoded	-0,02	0,00	0,07	1,00	-0,04
Education_Encoded	0,56	0,59	0,67	-0,04	1,00



Gambar 3.1 — Heatmap correlation matrix termasuk Gender_Encoded dan Education_Encoded

INSIGHT

- **Education_Encoded** memiliki korelasi moderat-kuat dengan Salary ($r = 0,67$) — tingkat pendidikan cukup berpengaruh terhadap besaran gaji, meski tidak sekuat Years of Experience.
- **Gender_Encoded** memiliki korelasi yang sangat lemah/hampir tidak ada terhadap Salary ($r = 0,07$), Age (-0,02), maupun Years of Experience (0,00) — menunjukkan tidak ada indikasi kesenjangan gaji yang signifikan secara linear berdasarkan gender pada dataset ini.
- Education_Encoded juga berkorelasi moderat dengan Age (0,56) dan Years of Experience (0,59) — masuk akal karena pendidikan yang lebih tinggi biasanya ditempuh di usia yang lebih matang.
- Perlu dicatat bahwa **LabelEncoder mengasumsikan urutan numerik pada kategori** (misalnya Education Level: High School=0, Bachelor's=1, Master's=2, PhD=3). Hasil korelasi ini valid karena Education Level memang memiliki urutan alami (ordinal), namun perlu kehati-hatian bila diterapkan pada kolom kategorikal yang tidak memiliki urutan (seperti Job Title).

Variabel Paling Berpengaruh terhadap Salary

Variabel	Korelasi terhadap Salary	Kategori Kekuatan
Years of Experience	0,93	Sangat Kuat
Age	0,92	Sangat Kuat
Education_Encoded	0,67	Moderat - Kuat
Gender_Encoded	0,07	Sangat Lemah

Identifikasi Variabel

Peran	Variabel	Keterangan
Variabel Dependen (Target/Akibat)	Salary	Nilai yang ingin diprediksi/dijelaskan
Variabel Independen (Penyebab Utama)	Years of Experience	Korelasi tertinggi terhadap Salary (0,93)
Variabel Independen (Pendukung)	Age, Education_Encoded	Agar, Education_Encoded, namun sebagian tumpang-tindih (redundan) dengan Years of Experience

KESIMPULAN & REKOMENDASI

- **Years of Experience** adalah prediktor terbaik untuk Salary pada dataset ini, dengan korelasi 0,93 — lebih kuat dibanding Age (0,92) dan Education_Encoded (0,67).
- Karena Age dan Years of Experience berkorelasi sangat tinggi satu sama lain (0,98), **menggunakan keduanya sekaligus sebagai variabel independen berisiko redundan (multikolinearitas)** jika dataset ini digunakan untuk model prediksi/regresi di masa depan.
- **Gender tidak menunjukkan pengaruh signifikan** terhadap gaji pada dataset ini (korelasi mendekati 0), yang merupakan temuan positif dari sisi kesetaraan gaji (pay equity) — meski tetap perlu divalidasi dengan uji statistik lain (bukan hanya korelasi linear) untuk kesimpulan yang lebih kuat.
- Untuk analisis atau model lanjutan, disarankan memilih **salah satu** antara Age atau Years of Experience (bukan keduanya) sebagai variabel utama, dan tetap menyertakan Education Level karena memberikan kontribusi informasi yang relatif independen.