

Univariate Analysis Report

Topik 4 — Exploratory Data Analysis (EDA)


Minggu 6 · Hari Selasa — Analisis Univariate

Dataset	Final_Clean_Dataset.csv
Jumlah Data	19.962 baris · 11 kolom
Kolom Dianalisis	Job_Description_Length, Job_Type, Sector, Location, Location_State, Organization
Metode	Statistik deskriptif, value_counts(), visualisasi univariate

Laporan ini menyajikan analisis univariate terhadap dataset lowongan pekerjaan. Setiap bagian memuat visualisasi, tabel ringkasan, dan insight yang relevan sebagai dasar pengambilan keputusan bisnis maupun perbaikan kualitas data.

1

Distribusi Job_Description_Length



Gambar 1.1 — Histogram distribusi panjang deskripsi pekerjaan

INSIGHT

- Mayoritas deskripsi pekerjaan memiliki panjang sekitar **1.500–2.500 karakter**, yang menjadi rentang paling umum (puncak histogram).
- Terdapat outlier dengan panjang deskripsi mencapai sekitar **20.000 karakter**, jauh di atas rata-rata.
- Distribusi condong ke kanan (right-skewed) — sebagian besar data terkumpul di sisi kiri, dengan ekor panjang ke arah nilai besar.


Tabel 1.1 — Distribusi Berdasarkan Rentang Karakter

Range Karakter	Jumlah	Persentase (%)
0-500	1.083	5,43
500-1000	2.009	10,06
1000-2000	5.751	28,81
2000-3000	5.192	26,01
3000-5000	4.605	23,07
5000-10000	1.272	6,37
10000+	50	0,25


INSIGHT

- Rentang **1000-2000** dan **2000-3000** karakter mendominasi, bersama mencakup lebih dari **54%** dari seluruh data — ini adalah standar umum panjang deskripsi pekerjaan.
- Deskripsi sangat singkat (0-500 karakter, 5,43%) berpotensi kurang informatif atau merupakan hasil kesalahan proses scraping data.
- Outlier dengan panjang lebih dari 10.000 karakter (0,25%) sangat jarang terjadi dan mungkin memuat informasi hukum tambahan atau persyaratan teknis yang sangat detail.

Boxplot — Deteksi Outlier



Gambar 1.2 — Boxplot sebaran panjang deskripsi pekerjaan




Gambar 2.1 — Proporsi tipe pekerjaan (Pie Chart)

Job_Type	Jumlah	Persentase (%)
Full Time	17.166	85,99
Contract/Temporary	1.762	8,83
Part Time	813	4,07
Other	148	0,74
Per Diem	65	0,33
Intern	8	0,04

INSIGHT

- **Full Time** sangat mendominasi dataset (85,99%), menunjukkan profil utama lowongan pada dataset ini adalah pekerjaan tetap.
- Tipe pekerjaan lain seperti Contract/Temporary dan Part Time jumlahnya jauh lebih kecil, menandakan pasar kerja pada dataset ini kurang fleksibel dari sisi jenis kontrak.
- Kategori **Intern** hanya 0,04% — sangat minim kesempatan bagi pencari kerja pemula/magang dalam dataset ini.
- Konsentrasi pada Full Time mencerminkan target audiens dataset, kemungkinan berasal dari sumber lowongan korporat/menengah-besar.



Gambar 3.1 — Distribusi lowongan berdasarkan sektor (Top 15 + Other)

Tabel 3.1 — Distribusi Lengkap Top 15 Sektor

Sector	Jumlah	Persentase (%)
Lainnya (Unknown)	4.840	24,25
Experienced (Non-Manager)	4.222	21,15
Entry Level	1.108	5,55
Medical/Health	1.060	5,31
Manager (Manager/Supervisor of Staff)	866	4,34
IT/Software Development	818	4,10
Sales/Retail/Business Development	790	3,96
Accounting/Finance/Insurance	664	3,33
Food Services/Hospitality	601	3,01
Installation/Maintenance/Repair	541	2,71
Manufacturing/Production/Operations	510	2,55
Project/Program Management	421	2,11
Logistics/Transportation	343	1,72
Marketing/Product	303	1,52
Customer Support/Client Care	297	1,49
Other (gabungan sektor kecil)	2.578	12,91

INSIGHT

- Kategori '**Lainnya**' (**Unknown**) menjadi yang terbesar (24,25%) — hampir 1 dari 4 lowongan tidak memiliki informasi sektor yang jelas, ini adalah isu kualitas data yang perlu dicatat.
- Kolom Sector tercampur antara **nama industri** (Medical/Health, IT/Software Development) dan **level pengalaman** (Experienced Non-Manager, Entry Level, Manager) — menunjukkan perlunya validasi/pemisahan kategori lebih lanjut.
- Sektor **Medical/Health** dan **IT/Software Development** berada di posisi atas, menandakan dataset ini cukup relevan untuk kedua industri tersebut.
- Kategori 'Other' yang menggabungkan sektor-sektor kecil (12,91%) menunjukkan long-tail distribution — banyak sektor dengan frekuensi rendah.

4

Distribusi Location (Top 10)

Location	Jumlah	Persentase (%)
Dallas, TX	556	2,79
Cincinnati, OH	304	1,52
Dallas, TX 75201	266	1,33
Columbus, OH	220	1,10
Houston, TX	186	0,93
Atlanta, GA	155	0,78
Location:	131	0,66
Austin, TX	130	0,65
Columbus, OH 43215	121	0,61
Chicago, IL	116	0,58


INSIGHT

- **Dallas, TX** menjadi lokasi dengan jumlah lowongan tertinggi, menunjukkan konsentrasi aktivitas rekrutmen di kota tersebut.
- Ditemukan **inkonsistensi penulisan lokasi** — misalnya 'Dallas, TX' dan 'Dallas, TX 75201' tercatat sebagai entitas berbeda padahal merujuk kota yang sama, begitu juga 'Columbus, OH' dan 'Columbus, OH 43215'. Ini berpotensi memecah jumlah sebenarnya dan perlu dibersihkan lebih lanjut.
- Ditemukan nilai anomali '**Location:**' (131 baris) yang tampaknya merupakan kesalahan hasil scraping data, bukan nama lokasi asli.
- Top 10 lokasi didominasi kota-kota di Texas dan Ohio, konsisten dengan temuan pada analisis Location_State.

Location_State	Jumlah	Persentase (%)
TX	2.792	13,99
OH	2.059	10,31
CA	1.597	8,00
FL	815	4,08
IL	813	4,07
GA	688	3,45
MA	678	3,40
PA	626	3,14
NY	626	3,14
WI	605	3,03

INSIGHT

- **Texas (TX)** dan **Ohio (OH)** memimpin jauh dibandingkan negara bagian lain, masing-masing menyumbang 13,99% dan 10,31% dari seluruh lowongan.
- Tiga negara bagian teratas (TX, OH, CA) bersama menyumbang lebih dari **32%** dari total lowongan — menunjukkan aktivitas rekrutmen sangat terpusat di beberapa wilayah ekonomi utama.
- Kesenjangan yang cukup jauh antara peringkat 1 (TX, 13,99%) dan peringkat 10 (WI, 3,03%) menunjukkan ketimpangan distribusi lowongan antarwilayah.
- Wilayah dengan persentase lebih rendah bisa menjadi area potensial untuk ekspansi rekrutmen jika industri yang dicari relevan.




Gambar 5.1 — Top 10 negara bagian berdasarkan jumlah lowongan

Organization	Jumlah	Persentase (%)
Healthcare Services	8.072	40,44
All	1.069	5,36
Other/Not Classified	951	4,76
Manufacturing - Other	835	4,18
Computer/IT Services	779	3,90
Retail	534	2,68
Legal Services	459	2,30
Business Services - Other	395	1,98
Restaurant/Food Services	367	1,84
Food and Beverage Production	320	1,60

INSIGHT

- **Healthcare Services** sangat dominan dengan 40,44% dari seluruh lowongan — menjadikannya pemberi kerja/industri paling aktif secara signifikan dibanding kategori lain.
- Nilai '**All**' dan '**Other/Not Classified**' yang cukup tinggi (bersama >10%) menunjukkan adanya isu kualitas data pada klasifikasi organisasi/industri.
- Dominasi Healthcare Services konsisten dengan temuan pada kolom Sector, di mana Medical/Health juga muncul sebagai kategori signifikan — menunjukkan dataset ini sangat relevan untuk industri kesehatan.
- Sisa organisasi (Retail, Legal Services, Manufacturing, dll.) memiliki porsi yang jauh lebih kecil dan cukup terdistribusi merata, mengindikasikan pasar kerja non-kesehatan yang lebih terfragmentasi.

Sebagai pelengkap, lima visualisasi kunci disatukan dalam satu dashboard untuk memudahkan perbandingan pola sekaligus antar-variabel.



Gambar 7.1 — Dashboard gabungan: Top 10 Lokasi, Top 10 Organisasi, Distribusi Panjang Deskripsi, Proporsi Sektor, dan Tipe Pekerjaan

RINGKASAN VISUALISASI TAMBAHAN

- Lokasi & Organisasi:** menunjukkan dominasi Dallas (TX) dan sektor Healthcare Services yang sangat masif (lebih dari 40% total data).
- Deskripsi:** sebagian besar pekerjaan menggunakan 1.000 hingga 5.000 karakter, yang merupakan standar profesional untuk deskripsi tugas dan kualifikasi.
- Sektor:** selain kategori 'Lainnya' dan 'Experienced', bidang medis dan IT tampil sebagai kontributor utama.
- Tipe Pekerjaan:** grafik batang mempertegas betapa jauhnya perbedaan jumlah antara lowongan 'Full Time' dengan tipe lainnya seperti 'Contract' atau 'Part Time'.

Secara keseluruhan, dataset ini didominasi oleh lowongan **Full Time** pada industri **Healthcare Services**, terkonsentrasi secara geografis di negara bagian **Texas dan Ohio**. Panjang deskripsi pekerjaan (Job_Description_Length) menunjukkan distribusi condong ke kanan dengan mayoritas berada di rentang 1.000–3.000 karakter.

Isu Kualitas Data yang Perlu Ditindaklanjuti

- Nilai **'Unknown'/'Lainnya'** pada kolom Sector mencapai 24,25% dari total data.
- **Inkonsistensi penulisan** pada kolom Location (contoh: 'Dallas, TX' vs 'Dallas, TX 75201') serta nilai anomali 'Location:'.
- Kategori **'All'** dan **'Other/Not Classified'** pada kolom Organization yang kurang informatif.
- Percampuran **nama sektor industri** dengan **level pengalaman** pada kolom Sector.